

Atelier de un ou deux jours en analyse de données.

Plan de l'Atelier d'Analyse de Données avec Pandas et Matplotlib

Jour 1 : Introduction à Pandas et Analyse Exploratoire des Données (EDA)

1. Bases de Pandas

- Préparez votre IDE pour une version de Python `≥ 3.11` et installez `pandas`, `pandas-stubs`, `openpyxl` et `matplotlib`.
- Configurez `pandas` afin que l'affichage par défaut des `DataFrames` affiche au minimum 6 colonnes, au maximum 12 colonnes, au maximum 100 lignes de contenu, au maximum 20 caractères par colonne et 240 caractères par ligne.
- Créez un `DataFrame` depuis des valeurs aléatoires, avec 20 colonnes et 200 lignes, et vérifiez que son affichage respecte la configuration que vous avez établie précédemment.
- Expliquez les concepts de base de Pandas, à savoir les `DataFrames`, les `Series` et les `Index`.

2. Chargement et Exploration des Données

- Chargez chaque feuille de calcul du fichier Excel dans des `DataFrame` séparés, pour des variables nommées respectivement :
 - orders
 - territoires
 - sales
 - resellers
 - dates
 - products
 - customers
- Affichez les cinq premières lignes de chaque `DataFrame` et vérifiez-en également les types de colonnes.
- Affichez des informations de base sur les `DataFrame` via les méthodes `info()` et `describe()` pour obtenir des informations sur la taille, les types de données et les valeurs manquantes dans chaque `DataFrame`.
- Si besoin, notez les colonnes qui ont un type qui semble incorrect vis-à-vis de leur usage.
- Affichez des informations de distribution (dispersion) du coût standard des produits du catalogue. Affichez la médiane, l'écart-type et la variance. Calculez

les mêmes informations, mais cette fois-ci par catégorie de produit (`Category`).

3. Nettoyage des Données

- Assurez-vous dans tous les `DataFrames` qu'il n'existe aucune cellule laissée vide. Si ce n'est pas le cas, affichez les identifiants des colonnes contenant des valeurs vides. Remplacez également ces valeurs par une valeur de repli si besoin.
- Vérifiez dans les ventes que le total des ventes est correct, notamment lorsque la valeur de remise (discount) est non nulle.
- Créez une colonne `Price ratio` calculant le multiplicateur entre le prix affiché et le coût du produit.
- Créez une colonne `Line number` dans `orders` extrayant le numéro de ligne de la colonne `Sales Order Line`.
- Traitez et convertissez les colonnes qui ne semblent pas avoir un type de données correct inféré pour l'analyse.
- Créez une colonne `Margin` représentant la marge entre les ventes et le coût total.

4. Analyse Exploratoire des Données (EDA)

- Affichez le total des ventes, réparti par territoire en utilisant des graphiques à barres. L'intitulé des barres doit être horizontal, et représenter le `Country` du territoire ainsi que la `Region` sur une seconde ligne. Sauvegardez le diagramme dans un fichier au format PNG.
- Affichez le total des ventes par `Model` de produit via une visualisation dans un graphique adapté (secteur ou barres). Sauvegardez également le diagramme dans un fichier au format PNG.
- Explorez les ventes par jour et identifiez les tendances saisonnières potentielles; créez des colonnes avec des moyennes de ventes lissées sur 7, et sur 30 jours. Affichez des graphiques en lignes pour voir ces tendances.
- Générez des tableaux croisés dynamiques (*pivot tables*) pour analyser les ventes par différentes dimensions (par exemple, *somme des ventes par produit et par territoire*).

Jour 2 : Analyse Avancée et Visualisation avec Matplotlib

5. Analyse Statistique des Données

- Affichez les informations statistiques classiques des ventes (moyenne, médiane, écart-type, minimum, maximum, premier quartile et troisième quartile) pour chaque territoire.
- Calculez la corrélation entre différentes variables :
 - Entre les ventes totales et les profits.
 - Entre le coût total et la marge.

- Identifiez les territoires et produits les plus performants en termes de ventes.
- Effectuez des tests statistiques pour vérifier les hypothèses, par exemple, l'écart type des ventes par territoire.

6. Visualisation Avancée avec Matplotlib

- Affichez un nuage de points (*scatter*) pour explorer les relations entre les variables (total des ventes en x, marge en y, et prix unitaire pour l'intensité des points).
- Créez des diagrammes à moustache (*box plot*) pour analyser la distribution en quartiles des ventes. Une boîte par territoire, valeurs de boîte par modèle de produit.
- Personnalisez les graphiques en ajoutant des titres, étiquettes et légendes :
 - Personnalisez la police
 - Personnalisez le thème de couleurs
 - Ajoutez des informations de valeur sur les barres des diagrammes
- Affichez une heat map (carte de chaleur ou matrice de corrélation) pour visualiser les corrélations entre les variables :
 - Entre le total de vente et la marge
- Créez des graphiques en secteur (pie) pour visualiser la part de marché des différents produits ou territoires. Affichez la part en pourcent et/ou en dollars dans les secteurs si possible.

7. Analyse Temporelle des Ventes

- Analysez les ventes par mois et créez une série temporelle (dont les Index sont des dates).
- Analysez les ventes par trimestre et par année.
- Visualisez les tendances des ventes au fil du temps avec des graphiques de séries temporelles (ex. bougies)

8. Fusion des Données pour une Analyse Globale

- Fusionnez les différentes tables de données pour obtenir une vue complète des ventes.
- Vérifiez bien que toutes les lignes de la table des ventes sont présentes dans le résultat.
- Réalisez une analyse croisée des données :
 - Ventes par produit et par territoire,
 - Nombre de produits par modèle,
 - Clients avec le plus de commandes,
 - Clients ayant le plus dépensé,
 - Nombre de ventes par catégorie de produit par territoire
- Complétez les visualisations précédentes pour représenter les ventes globales par différentes dimensions (produit, territoire, période).

9. Analyse des Performances des Revendeurs

- Analysez les ventes par revendeur et identifiez les revendeurs les plus performants.
- Visualisez les performances des revendeurs avec des graphiques à barres et des diagrammes circulaires.
- Comparez les performances des revendeurs sur différentes périodes.

10. Présentation

- Lors de votre présentation, imaginez-vous à la place d'un bureau de décision.
- Par rapport aux graphiques et aux données extraites, quels conseils ou quelles questions vous semblent pertinentes pour améliorer les performances de l'entreprise ?
- Quels autres graphiques auriez-vous pu générer ? (prévisionnel, etc.)
- Quelles données supplémentaires auriez-vous souhaité avoir pour proposer des améliorations ?

Documentation à Utiliser

- Documentation officielle de Pandas : [Pandas Documentation](#)
- Documentation officielle de Matplotlib : [Matplotlib Documentation](#)